

PROJET FINAL DE DEEP LEARNING
ANNÉE SCOLAIRE 2025-2026
UNIVERSITÉ PARIS CITÉ

Comparaison de la classification
d'images par CNN et Visual
Transformers

UE MA7CY070

Réalisé par:

Asma AL RIFAI
Réhane ARICAT

Professeur:

Mme. Ilaria Giulini

01 Avril 2026

Contents

1	Visual Transformers	3
1.1	Principe des Visual Transformers	3
1.1.1	La transformation en tokens	3
1.1.2	L'encodeur	3
1.1.3	Tête de projection	5
1.2	Limites et forces des Visual Transformers	5
2	CNN	6
2.1	Principe des CNN	7
2.1.1	Les couches de convolution	7
2.1.2	Le pooling	8
2.1.3	Empilement des couches	8
2.1.4	Les couches entièrement connectées	8
2.2	Architecture globale d'un CNN	9
2.3	Lien avec le modèle AlexNet (2012)	9
2.4	Avantages et limites des CNN	10
3	Comparaisons entre les modèles	10
3.1	Dataset de petite taille	10
3.1.1	Principe du test	10
3.1.2	Le dataset	11
3.1.3	Architectures implémentées	11
3.1.4	Résultats	12
3.2	Dataset de textures	15
3.2.1	Principe du test	15
3.2.2	Le dataset	15
3.2.3	Résultats	17
3.3	Dataset de relation spatiale	19
3.3.1	Principe du test	19
3.3.2	Le dataset	19
3.3.3	Les architectures choisies	20
3.3.4	Résultats	20
3.4	Dataset d'interactions globales	23
3.4.1	Principe du test	23
3.4.2	Le dataset	23
3.4.3	Les architectures choisies	23
3.4.4	Résultats	24
4	Conclusion	25

Liste des figures

1	Schéma du modèle Visual Transformer tirée de Dosovitskiy et al. (2021)	5
2	Architecture typique d'un réseau convolutionnel	9
3	Images tirées du dataset CIFAR10	12
4	Loss durant l'apprentissage sur différents subsets de CIFAR-10	13
5	Accuracy durant l'apprentissage sur différents subsets de CIFAR-10	13
6	Accuracy sur ensemble de test pour différentes tailles de subsets de CIFAR-10	14
7	Accuracy finale sur ensemble de test pour différentes tailles de subsets de CIFAR-10	14
8	Temps d'entraînement pour différentes tailles de subsets de CIFAR-10	15
9	Dataset de texture	16
10	Loss de training sur dataset de texture	17
11	Accuracy de training sur dataset de texture	17
12	Accuracy de test sur dataset de texture	18
13	Temps d'entraînement sur dataset de texture	18
14	Dataset de relation spatiale : où se trouve le cercle par rapport à la figure rouge ?	19
15	Loss durant l'apprentissage sur dataset de relations spatiales .	21
16	Accuracy durant l'apprentissage sur dataset de relations spatiales	21
17	Accuracy sur l'ensemble de test lors de l'apprentissage sur dataset de relations spatiales	22
18	Accuracy finale sur ensemble de test sur dataset de relations spatiales	22
19	Temps d'entraînement sur dataset de relations spatiales	22
20	Accuracy de training sur dataset de relations globales	24
21	Accuracy de training sur dataset de relations globales	24
22	Accuracy de test sur dataset de relations globales	25

1 Visual Transformers

Les modèles de réseaux de neurones basés sur le principe de "self-attention", en particulier les Transformers, introduits dans le papier "Attention is All You Need" (Vaswani et al., 2017), sont devenus le standard pour les tâches de traitement du langage naturel.

En s'inspirant des Transformers, l'article "An image is worth 16x16 words: Transformers for image recognition at scale" (Alexey Dosovitskiy, 2020) propose les Visual Transformers (ViT) qui utilisent également des mécanismes d'attention pour le traitement des images. En particulier, un ViT se compose des trois étapes majeures suivantes : la transformation en tokens, l'encodeur et la tête de projection.

1.1 Principe des Visual Transformers

1.1.1 La transformation en tokens

Une image est représentée comme un tenseur $x \in \mathbb{R}^{H \times W \times C}$ où $(H \times W)$ est la résolution de l'image et C est le nombre de canaux de couleur (ici, on utilise $C = 3$ pour le système (R, G, B)). Dans un premier temps, l'image est divisée en une séquence de patches $x_p \in \mathbb{R}^{N \times (P^2 \times C)}$ où $N = HW/P^2$ est le nombre total de patches.

Chaque patch est transformé en un vecteur d'embeddings de dimension D par l'opération

$$x_e = [x_p^1 E; x_p^2 E; x_p^3 E; \dots; x_p^N E] \in \mathbb{R}^{N \times D}$$

où chaque patch est multiplié par une matrice d'embedding, dont les paramètres sont appris à l'entraînement.

Ensuite, un embedding de position est ajouté. Il représente la position d'un token dans la séquence. Les embeddings de position sont nécessaires car les mécanismes d'attention ne prennent pas en compte l'ordre des tokens d'une séquence.

$$x_{token} = x_e + x_{pos}$$

Enfin, on ajoute en début de séquence, un token de classification dont les paramètres d'embedding sont appris et qui condense l'information de l'image entière. Cette séquence de tokens est utilisée comme input de l'encodeur.

1.1.2 L'encodeur

L'encodeur est formé de plusieurs blocs successifs. Chaque bloc se compose d'une couche de Multi-Head Attention et d'un réseau de neurones

Feed-Forward, entourés de mécanismes de normalisation et de connexions résiduelles.

Multi-head attention

Les mécanismes d'attention permettent d'encoder les relations entre un token et chaque autre token de la séquence, en attribuant un poids plus important aux tokens les plus pertinents.

Pour cela, on associe à chaque token trois vecteurs : query **Q**, key **K** et value **V**, obtenus par projections linéaires apprises.

Le score d'attention d'un token j par rapport à un token i est donné par :

$$a_{ij} = \frac{Q_i K_j^T}{\sqrt{d_k}}$$

où d_k est la dimension des vecteurs de key. Le facteur $\sqrt{d_k}$ permet de stabiliser les gradients.

Les coefficients d'attention sont ensuite normalisés par une fonction softmax :

$$\alpha_{ij} = \text{softmax}(a_{ij})$$

Le vecteur de sortie pour le token i est alors :

$$\sum_j \alpha_{ij} V_j$$

Il s'agit d'un vecteur qui résume les relations qu'entretient le token i avec tous les autres tokens de l'image. Dans le cas du Multi-Head Attention, plusieurs mécanismes d'attention sont appliqués en parallèle (les *heads*), permettant au modèle de capturer différents types de relations. Les résultats sont ensuite concaténés et projetés linéairement.

Chaque bloc d'attention est suivi d'une **connexion résiduelle** et d'une **normalisation** (LayerNorm) :

$$z' = \text{LayerNorm}(z + \text{MHA}(z))$$

Le réseau Feed-Forward

Le vecteur résultant du mécanisme d'attention est ensuite traité indépendamment pour chaque token par un réseau Feed-Forward entièrement connecté, généralement composé de deux couches linéaires séparées par une fonction d'activation :

$$\text{FFN}(x) = \sigma(xW_1 + b_1)W_2 + b_2$$

Comme pour la couche d'attention, une connexion résiduelle et une normalisation sont appliquées :

$$z'' = \text{LayerNorm}(z' + \text{FFN}(z'))$$

Enfin, ces blocs sont empilés plusieurs fois.




Figure 1: Schéma du modèle Visual Transformer tirée de Dosovitskiy et al. (2021)

1.1.3 Tête de projection

À la sortie de l'encodeur, seul le token de classification (noté [CLS]) est utilisé. Ce token agrège l'information globale de l'image.

Il est ensuite passé dans une tête de projection, généralement un perceptron multicouche (MLP), afin de produire la prédiction finale :

$$y = \text{MLP}(x_{\text{CLS}})$$

Dans le cas d'une tâche de classification, une fonction softmax est appliquée pour obtenir une distribution de probabilités sur les classes.

1.2 Limites et forces des Visual Transformers

Les Visual Transformers (ViT) ont montré des performances remarquables sur de nombreuses tâches de vision par ordinateur, notamment lorsqu'ils sont entraînés à grande échelle.

Leur principal atout réside dans leur capacité à modéliser des dépendances à longue distance grâce aux mécanismes de self-attention, contrairement aux réseaux convolutionnels qui sont intrinsèquement locaux. Cette propriété leur permet de capturer des relations globales entre différentes régions de l'image.

Cependant, ces modèles présentent également plusieurs limitations importantes.

Tout d'abord, les ViT possèdent un biais inductif beaucoup plus faible que les réseaux de neurones convolutionnels (CNN). Dans les CNN, des propriétés telles que la localité, la structure de voisinage bidimensionnelle et l'invariance par translation sont intégrées directement dans l'architecture. À l'inverse, dans les ViT, ces propriétés ne sont pas explicitement encodées.

En effet, les couches d'attention sont globales et seules les couches MLP conservent une forme de localité. La structure spatiale de l'image est peu exploitée, hormis lors de la division initiale en patches et via les embeddings de position. Mais malgré les embeddings de position, l'image transformée en séquence de patches aplatis perd sa structure 2D et ses relations de voisinage. Ceci implique que toutes les relations spatiales doivent être apprises à partir des données.

Cette faible contrainte structurelle, bien qu'elle confère une grande flexibilité au modèle, constitue également une faiblesse. En particulier, les ViT ont tendance à nécessiter de très grandes quantités de données pour apprendre efficacement. Par exemple, le modèle ViT original est pré-entraîné sur des jeux de données massifs comme JFT-300M, puis affiné sur ImageNet-1K. Dans ce cadre, il surpasse les CNN classiques. En revanche, lorsqu'il est entraîné uniquement sur des jeux de données plus modestes, ses performances chutent significativement.

Néanmoins, lorsque les ViT sont entraînés sur des jeux de données de très grande taille (de l'ordre de plusieurs millions à centaines de millions d'images), ces limitations deviennent moins problématiques. Dans ce contexte, l'échelle des données compense largement l'absence de biais inductif, et les ViT peuvent atteindre, voire dépasser, les performances des CNN.

Ces constats ont motivé le développement de modèles hybrides combinant convolutions et mécanismes d'attention, plus efficaces et permettant de réduire la dépendance des Transformers au grand nombre de données.

2 CNN

Les réseaux de neurones convolutionnels (Convolutional Neural Networks, CNN) sont des modèles conçus pour le traitement des données structurées en grille, comme les images. Ils exploitent directement la structure spatiale des données en appliquant des opérations locales.

Contrairement aux Visual Transformers, les CNN reposent sur des biais inductifs forts : la localité des interactions, le partage des poids et une invariance partielle par translation. Ces propriétés réduisent le nombre de

paramètres à apprendre et permettent une meilleure généralisation lorsque les données sont limitées.

Un CNN est généralement composé d'une succession de couches de convolution, de fonctions d'activation, de couches de pooling et de couches entièrement connectées.

2.1 Principe des CNN

2.1.1 Les couches de convolution

Une image est représentée par un tenseur

$$x \in \mathbb{R}^{H \times W \times C}$$

où H est la hauteur de l'image, W sa largeur et C le nombre de canaux (par exemple $C = 3$ pour RGB).

Une couche de convolution applique un ensemble de filtres de taille réduite (par exemple 3×3) qui parcourent l'image. Chaque filtre est conçu pour détecter un motif local spécifique, comme un bord, une texture ou une orientation particulière.

La convolution s'écrit :

$$y(i, j) = \sum_m \sum_n x(i + m, j + n) \cdot w(m, n)$$

où :

- $x(i + m, j + n)$ est la valeur du pixel d'entrée,
- $w(m, n)$ est le poids du filtre,
- $y(i, j)$ est la valeur de sortie à la position (i, j) ,
- m, n parcourent la taille du filtre.

Chaque filtre produit une carte de caractéristiques. L'utilisation de plusieurs filtres permet de capturer différents types d'informations locales dans l'image. Après la convolution, une fonction d'activation non linéaire est appliquée. La plus utilisée est ReLU :

$$\text{ReLU}(x) = \max(0, x)$$

Cette étape introduit la non-linéarité qui indispensable pour modéliser des relations complexes. Elle s'applique élément par élément sur la sortie.

2.1.2 Le pooling

Les couches de pooling permettent de réduire la résolution spatiale des cartes de caractéristiques.

L'opération la plus courante est le max-pooling, qui sélectionne la valeur maximale dans une fenêtre locale :

$$y(i, j) = \max_{(m, n) \in \mathcal{W}} x(i + m, j + n)$$

Cette opération conserve les informations les plus importantes tout en réduisant la taille des données.

Le pooling a plusieurs effets :

- réduction du coût de calcul,
- diminution du risque de sur-apprentissage,
- introduction d'une invariance locale aux translations.

2.1.3 Empilement des couches

Un CNN profond est obtenu en empilant plusieurs blocs convolution + activation + pooling.

Les premières couches apprennent des motifs simples comme les contours ou les gradients de couleur. Les couches intermédiaires combinent ces motifs pour former des textures ou des parties d'objets. Les couches profondes capturent des structures plus abstraites.

Cette organisation hiérarchique permet de construire progressivement une représentation riche de l'image.

2.1.4 Les couches entièrement connectées

À la fin du réseau, les cartes de caractéristiques sont transformées en un vecteur via une opération d'aplatissement.

Ce vecteur est ensuite traité par une ou plusieurs couches entièrement connectées, qui combinent les caractéristiques extraites pour produire une prédiction :

$$y = \text{MLP}(x)$$

où :

- x est le vecteur d'entrée,
- y est la sortie du modèle,




Figure 2: Architecture typique d'un réseau convolutionnel

- MLP désigne un réseau de neurones entièrement connecté.

Dans le cas de la classification, une fonction softmax est appliquée afin d'obtenir une distribution de probabilité sur les classes.

2.2 Architecture globale d'un CNN

Les premières couches extraient des caractéristiques locales (convolution, pooling), puis les couches finales réalisent la classification.

Un CNN suit généralement une structure en deux phases.

Dans une première phase, plusieurs couches convolutionnelles extraient progressivement des caractéristiques de plus en plus abstraites.

Dans une seconde phase, ces caractéristiques sont utilisées par des couches entièrement connectées pour effectuer la classification.

Cette organisation permet de passer d'une représentation locale des pixels à une représentation globale de l'image.

2.3 Lien avec le modèle AlexNet (2012)

Le modèle AlexNet (Krizhevsky et al., 2012) constitue une avancée majeure dans l'histoire des CNN. Il a démontré l'efficacité des réseaux profonds pour la classification d'images à grande échelle, notamment sur le dataset ImageNet. L'architecture comporte cinq couches de convolution suivies de trois couches entièrement connectées. Elle introduit plusieurs éléments devenus standards. L'utilisation de la fonction ReLU permet une convergence plus rapide que les fonctions d'activation classiques.

Le dropout est utilisé dans les couches finales pour limiter le sur-apprentissage en désactivant aléatoirement des neurones pendant l'entraînement. La data augmentation est appliquée afin d'augmenter la diversité des données d'entraînement, notamment par des transformations géométriques simples. Le modèle exploite également la puissance des GPU pour rendre possible l'entraînement d'un réseau profond sur un grand volume de données. Enfin, l'utilisation du pooling chevauchant améliore légèrement la généralisation. Ces contributions ont permis à AlexNet de remporter la compétition ImageNet 2012 avec une amélioration significative des performances, marquant le début de l'utilisation massive du deep learning en vision par ordinateur.

2.4 Avantages et limites des CNN

Les CNN présentent plusieurs avantages importants. Ils exploitent efficacement la structure spatiale des images grâce aux convolutions locales. Ce biais inductif facilite l'apprentissage et améliore la généralisation, en particulier lorsque les données sont limitées. Le partage des poids réduit fortement le nombre de paramètres, ce qui rend le modèle plus efficace et moins sensible au sur-apprentissage. L'invariance par translation permet de reconnaître un objet même s'il change de position dans l'image. Cependant, les CNN présentent aussi des limites. Leur champ réceptif est initialement local. Même si celui-ci augmente avec la profondeur, les interactions entre régions éloignées restent indirectes. Ils sont donc moins adaptés à la modélisation explicite de dépendances globales que les modèles à attention. Enfin, leur structure impose des contraintes fortes sur la représentation des données, ce qui peut limiter leur flexibilité dans certains contextes. Ces caractéristiques expliquent pourquoi les CNN sont particulièrement performants sur des jeux de données de taille modérée, tandis que les Transformers deviennent plus compétitifs à grande échelle.

3 Comparaisons entre les modèles

3.1 Dataset de petite taille

3.1.1 Principe du test

Dans un premier temps, nous avons cherché à illustrer le comportement des modèles lorsque les données disponibles sont limitées, en entraînant des modèles implémentés entièrement par nos soins.

L'idée générale de cette expérience est inspirée de Lu et al. 2022. En effet, il a été observé que les ViTs présentent un écart de performance très marqué par rapport aux CNNs lorsqu'ils sont entraînés à partir de zéro (sans pré-entraînement) sur de petits jeux de données, ce qui est généralement attribué à l'absence de biais inductif.

Ainsi, dans notre expérience, on s'attend à ce que le ViT soit significativement moins performant que le CNN dans un régime de faible quantité de données.

3.1.2 Le dataset

Pour mener ce test, nous avons choisi le dataset CIFAR-10 **cifar10**, largement utilisé comme référence dans de nombreux travaux en vision par ordinateur. Il se compose de 60 000 images couleur de taille 32x32 réparties en 10 classes, avec 6 000 images par classe. Le jeu d'entraînement contient 50 000 images et le jeu de test 10 000 images, soit exactement 5 000 images par classe dans le training set.

Nous avons réalisé plusieurs entraînements en réduisant progressivement la taille du training set afin de tracer une courbe d'évolution des performances. Pour garantir une meilleure évaluation de l'erreur de test, le jeu de test complet est conservé, et la réduction ne s'applique qu'au jeu d'entraînement.

3.1.3 Architectures implémentées

Nous implémentons une version simplifiée du Vision Transformer ViT-Base (issu de Dosovitskiy et al. 2021), mais au nombre de paramètres réduits : ViT Tiny (Wu 2025).

ViT Tiny nous permet d'entraîner un modèle ViT avec un nombre de paramètres plus restreints, ce qui convient mieux aux machines avec peu de ressources computationnelles (peu de mémoire, pas de GPU,...).

Les paramètres tirés de Wu 2025 sont les suivants :

- 12 têtes d'attention
- 9 blocs d'encodeur
- 64 patches de taille 4x4 en input
- L'optimiseur utilisé est Adam avec un learning rate qui commence à 0,002, augmente progressivement pendant 10 epochs (warmup), puis décroît ensuite suivant une courbe cosinus. Le weight decay est fixé à 0,05.

On implémente un CNN dont l'architecture s'inspire de VGGNet Simonyan and Zisserman 2014, dans l'esprit de l'AlexNet original cité par l'énoncé :




Figure 3: Images tirées du dataset CIFAR10

- 4 blocs convolutifs avec filtres 3×3 empilés, BatchNorm et ReLU
- MaxPooling après chaque bloc $\rightarrow$ champ réceptif croissant
- Dropout pour régularisation
- 3 couches fully-connected avec Dropout fort (0.5) en tête

3.1.4 Résultats

Les résultats obtenus montrent que les CNN présentent une meilleure capacité de généralisation que les ViTs dans un régime de faible quantité de données, avec un écart de performance de l'ordre de 10 à 20%. Les figures 6 et 7 d'accuracy sur notre ensemble de test illustrent cette différence en fonction de la taille du jeu d'entraînement.

Par ailleurs, les ViTs montrent une forte tendance au sur-apprentissage pour des tailles de dataset comprises entre 10 000 et 50 000 exemples, caractérisée par une accuracy d'entraînement proche de 100% et une perte quasi nulle, mais avec des performances de test nettement inférieures. Ce comportement s'explique notamment par leur grande flexibilité, qui est elle-même liée à l'absence de biais inductif.

Ces résultats mettent en évidence le rôle crucial des biais inductifs dans les régimes de faible quantité de données, et justifient le recours au pré-entraînement sur de très grands ensembles de données pour les ViTs (typiquement de l'ordre du million d'images ou plus).




Figure 4: Loss durant l'apprentissage sur différents subsets de CIFAR-10




Figure 5: Accuracy durant l'apprentissage sur différents subsets de CIFAR-10




Figure 6: Accuracy sur ensemble de test pour différentes tailles de subsets de CIFAR-10



Figure 7: Accuracy finale sur ensemble de test pour différentes tailles de subsets de CIFAR-10




Figure 8: Temps d’entraînement pour différentes tailles de subsets de CIFAR-10

3.2 Dataset de textures

3.2.1 Principe du test

Un CNN applique des filtres convolutifs locaux qui détectent de manière naturelle des patterns répétitifs. Dans cette expérience, nous cherchons à mettre en évidence l’impact de ces biais inductifs locaux dans l’apprentissage de structures à motifs simples.

À l’inverse, un Vision Transformer, dépourvu de ce biais inductif, doit apprendre ces structures via le mécanisme d’attention, ce qui nécessite en général un nombre plus important d’exemples. Ainsi, on s’attend à ce que le CNN soit significativement plus performant que le ViT sur ce type de tâche, où les régularités spatiales sont essentielles.

3.2.2 Le dataset

Le dataset utilisé dans cette expérience est un jeu de données synthétique composé de six classes de textures : lignes horizontales, lignes verticales, damier, lignes diagonales, cercles concentriques et motifs radiaux. Chaque image est de taille 32×32 en RGB (trois canaux), avec une colorisation aléatoire introduite afin de rendre la tâche plus difficile et plus réaliste.




Figure 9: Dataset de texture




Figure 10: Loss de training sur dataset de texture




Figure 11: Accuracy de training sur dataset de texture

3.2.3 Résultats

Les résultats obtenus sur ce dataset mettent en évidence un comportement globalement très performant des deux architectures. En raison de la simplicité des motifs à reconnaître, l'entraînement est particulièrement rapide et les modèles atteignent des performances proches de 100 % aussi bien sur le jeu d'entraînement que sur le jeu de test.

Néanmoins, une légère différence de dynamique d'apprentissage peut être observée : le Vision Transformer nécessite une epoch supplémentaire pour atteindre ce niveau de performance (convergence autour de l'epoch 2, contre l'epoch 1 pour le CNN 12). Cette observation suggère que, même dans un cadre simple, le ViT doit d'abord apprendre les structures de motifs avant de pouvoir les exploiter efficacement, tandis que le CNN bénéficie de ses filtres convolutifs, qui lui permettent de capter immédiatement les motifs répétitifs. Cette différence, bien que faible dans ce contexte, reste cohérente avec l'idée que les architectures convolutionnelles disposent d'un biais inductif plus adapté à ce type de données.




Figure 12: Accuracy de test sur dataset de texture




Figure 13: Temps d'entraînement sur dataset de texture




Figure 14: Dataset de relation spatiale : où se trouve le cercle par rapport à la figure rouge ?

3.3 Dataset de relation spatiale

3.3.1 Principe du test

Dans un second temps, nous avons cherché à analyser le comportement des modèles sur une tâche nécessitant la compréhension de relations spatiales 2D entre objets.

L'idée de cette expérience s'inscrit dans la continuité des travaux précédents sur les différences fondamentales entre CNN et Vision Transformers Lu et al. 2022. En particulier, les CNN bénéficient d'un biais inductif fort lié à la structure de voisinage 2D. À l'inverse, les ViTs reposent sur un mécanisme d'attention globale, sans hypothèse structurelle a priori sur l'organisation spatiale des données. En effet, dans les ViTs, la structure 2D n'est que très peu utilisée ; au début lors de la découpe en patchs. Mais les embeddings de position ne possèdent aucune information sur la structure 2D. Puisque les vecteurs de patch sont aplatis, elle doit être apprise par le ViT (Dosovitskiy et al. 2021).

Ainsi, cette expérience vise à évaluer si cette absence de biais inductif constitue un inconvénient dans un contexte où la classification se base explicitement sur des relations spatiales. On s'attend notamment à observer des différences de comportement en faveur des CNN.

3.3.2 Le dataset

Pour cette expérience, nous utilisons un dataset synthétique de relations spatiales. Chaque image contient plusieurs objets géométriques simples (par exemple des formes telles que des cercles, carrés ou triangles), disposés selon des relations spatiales (à gauche de, au-dessus de, à droite de, en dessous

de). L'objectif du modèle est de prédire la relation spatiale entre deux objets "cible".

En plus des deux formes "cibles", on ajoute d'autres formes afin de bruite les données. Le dataset est construit de manière à faire varier aléatoirement le nombre d'objets, leur position, ainsi que le type de relation à prédire. Nous séparons les données en un jeu d'entraînement de taille 10000 et un jeu de test de taille 2000.

3.3.3 Les architectures choisies

Dans ce cadre expérimental, nous disposons d'un nombre limité de données d'entraînement (10 000 observations). Dans un tel contexte, l'utilisation de modèles pré-entraînés apparaît particulièrement pertinente, car elle permet de bénéficier de représentations déjà apprises sur des jeux de données de grande taille, améliorant ainsi la capacité de généralisation. Ce choix est d'autant plus justifié au regard des résultats observés lors des expériences sur petits datasets, où les modèles entraînés depuis zéro montraient des performances limitées.

Nous considérons ainsi deux architectures. La première est un modèle Tiny ViT-16 issu du package `timm`, dont nous adaptons uniquement la tête de classification ainsi que deux blocs de transformation, afin de tirer parti des représentations préalablement apprises tout en limitant le nombre de paramètres à ajuster.

La seconde architecture est MobileNetV3-Small, choisie pour son nombre réduit de paramètres. Il est donc très adapté à notre contrainte de données, les capacités de nos appareils et pertinent pour la comparaison avec le Tiny ViT. Dans ce cas, nous entraînons la tête de classification ainsi que les dernières couches du réseau.

3.3.4 Résultats

Les résultats mettent en évidence des différences significatives entre les deux types d'architectures. En particulier, le modèle de type Vision Transformer présente des performances de généralisation très faibles, avec une accuracy de test finale de 36,7 %, inférieure au niveau attendu pour une prédiction aléatoire (50 %). Un tel résultat suggère que le modèle ne parvient pas à capturer la structure sous-jacente de la tâche et peut même apprendre des corrélations non pertinentes qui dégradent ses performances hors échantillon. À l'inverse, l'architecture CNN obtient de bien meilleurs résultats, ce qui démontre sa capacité à exploiter efficacement les régularités spatiales présentes




Figure 15: Loss durant l'apprentissage sur dataset de relations spatiales




Figure 16: Accuracy durant l'apprentissage sur dataset de relations spatiales




Figure 17: Accuracy sur l'ensemble de test lors de l'apprentissage sur dataset de relations spatiales




Figure 18: Accuracy finale sur ensemble de test sur dataset de relations spatiales




Figure 19: Temps d'entraînement sur dataset de relations spatiales

dans les données. Il obtient d'ailleurs de bonnes performances de test dès 8 epochs.

Par ailleurs, le temps d'entraînement du Vision Transformer est significativement plus élevé, malgré un nombre de paramètres comparable (890 500 pour le ViT contre 945 492 pour le CNN). Ce constat confirme nos hypothèses quant au rôle des biais inductifs : les réseaux convolutionnels, grâce à leur structure intrinsèquement adaptée aux relations spatiales, apparaissent plus efficaces et plus économes en données dans ce type de tâche, tandis que les Transformers nécessiteraient sûrement plus de données pour apprendre ces structures.

3.4 Dataset d'interactions globales

3.4.1 Principe du test

Dans cette section, l'objectif est d'illustrer la capacité des Vision Transformers à exploiter des dépendances globales dans une image. Grâce à leur mécanisme d'attention, les ViTs sont en mesure de considérer simultanément l'ensemble des patches et de modéliser des interactions à longue portée entre différentes régions de l'image.

À l'inverse, les réseaux convolutionnels sont plus naturellement avantagés pour des tâches reposant sur des motifs locaux.

Ainsi, cette expérience vise à mettre en évidence un cas où le biais inductif des CNNs peut devenir limitant, tandis que l'approche globale des Transformers constitue un avantage. On s'attend donc à ce que le ViT soit plus performant que le CNN sur une tâche nécessitant une agrégation d'information à l'échelle de l'image entière.

3.4.2 Le dataset

Le jeu de données utilisé est composé d'images synthétiques contenant plusieurs formes géométriques. La tâche de classification consiste à déterminer si le nombre de cercles présents dans une image est pair ou impair. En complément, d'autres formes géométriques sont ajoutées afin d'introduire du bruit et de rendre la tâche plus difficile.

3.4.3 Les architectures choisies

Les modèles entraînés sont les mêmes que ceux de la tâche d'apprentissage de relations spatiales.




Figure 20: Accuracy de training sur dataset de relations globales




Figure 21: Accuracy de training sur dataset de relations globales

3.4.4 Résultats

Les résultats obtenus dans cette expérience apparaissent contre-intuitifs au regard de nos hypothèses initiales. En effet, aucune des deux architectures ne parvient à obtenir de bonnes performances en généralisation. Le Vision Transformer pré-entraîné atteint une accuracy d'entraînement d'environ 66 %, mais sa performance sur le jeu de validation reste proche du hasard ($\approx 50\%$), ce qui indique qu'il n'apprend que d'éléments généralisables. De son côté, le CNN pré-entraîné atteint presque 100 % de précision sur le jeu d'entraînement, mais sa performance en test est autour de 52 %, révélant un fort sur-apprentissage.

Ce résultat suggère que le biais inductif local des CNNs limite leur capacité à résoudre une tâche reposant sur un raisonnement global, comme le comptage.

Cependant, on peut s'interroger quant aux faibles performances du ViT. Une explication probable réside dans un décalage important entre la tâche de pré-entraînement (classification d'images naturelles de type ImageNet) et la tâche cible, qui repose ici sur un comptage de formes géométriques. Dans ce contexte, les représentations apprises lors du pré-entraînement sont peu adaptées.

Cette limitation est renforcée par le fait que seul un sous-ensemble du modèle (deux blocs et la tête de classification) est ajusté, obligeant le réseau à




Figure 22: Accuracy de test sur dataset de relations globales

s'appuyer largement sur des features pré-apprises inadéquates.

Plus généralement, ces résultats illustrent que le transfer learning n'est efficace que lorsque les représentations apprises sont alignées avec la structure de la tâche cible. Cette contrainte semble particulièrement critique pour les Vision Transformers, qui dépendent fortement de la qualité des représentations globales apprises, tandis que les CNNs bénéficient d'heuristiques inductives plus robustes, bien que parfois limitantes.

4 Conclusion

Ce projet avait pour objectif de comparer les CNN et les Vision Transformers en classification d'images, en concevant des datasets mettant explicitement en évidence leurs différences architecturales. L'enjeu central était d'identifier des contextes où chaque modèle excelle et d'en expliquer les raisons.

Les expériences menées ont permis de mettre en évidence le rôle déterminant des biais inductifs. Les CNN se sont révélés particulièrement efficaces sur des tâches reposant sur des structures locales et la structure 2D d'une image. À l'inverse, les Vision Transformers, dépourvus de ce biais, nécessitent davantage de données pour apprendre ces structures, ce qui pénalise leurs performances dans des régimes de faible quantité de données ou en l'absence de pré-entraînement adapté.

Cependant, les résultats ont également montré que les Transformers ne domi-

nent pas systématiquement sur les tâches globales. Dans l'expérience de comptage, où l'on pouvait s'attendre à un avantage des ViTs, les performances sont restées limitées, en grande partie en raison d'un décalage entre les représentations apprises lors du pré-entraînement et la nature de la tâche cible. Cela souligne une limite importante du transfer learning : son efficacité dépend fortement de l'alignement entre les données de pré-entraînement et le problème étudié.

Ainsi, ce travail met en évidence plusieurs compromis. Pour les CNN le compromis entre les biais inductifs qui les rendent efficaces sur certaines tâches, mais les limitent dès que ces biais ne sont plus adaptés

Pour les Vision Transformers, il y a un compromis entre leur grande flexibilité et la grande quantité de données nécessaires pour s'adapter à la tâche d'apprentissage.

References

- Dosovitskiy, Alexey et al. (2021). "An Image is Worth 16X16 Words: Transformers for Image Recognition at Scale". In: *ICLR 2021*.
- Lu, Zhiying et al. (2022). "Bridging the Gap Between Vision Transformers and Convolutional Neural Networks on Small Datasets". In: *NeurIPS*.
- Simonyan, Karen and Andrew Zisserman (2014). "Very Deep Convolutional Networks for Large-Scale Image Recognition". In: *SSRN Electronic Journal*.
- Wu, Gent (2025). "Powerful Design of Small Vision Transformer on CIFAR10". In.